Klasifikasi Hasil Panen Tanaman Menggunakan Naive Bayes dan Decision Tree pada Smart Crop Yield Prediction Dataset

Naufal Zainul Zaki1,a), Ika Kurniati1,b), and Sabian Franstiawan1,c)

1 Afiliasi penulis belum dicantumkan pada laporan asli, Indonesia.

a) Corresponding author: Naufalzainuzaki@webmail.umm.ac.id

b) Ikakurniati02@webmail.umm.ac.id

c) sabianumm@webmail.umm.ac.id

Abstract. Penelitian ini menyusun alur klasifikasi hasil panen tanaman berdasarkan Smart Crop Yield Prediction Dataset. Dataset memuat 10.000 observasi, 12 atribut prediktor awal, dan satu target numerik Yield_ton_per_ha. Berbeda dari laporan awal yang memposisikan target sebagai kasus regresi, penelitian ini mengubah target numerik menjadi tiga kelas produktivitas, yaitu Low, Medium, dan High, menggunakan kuantil. Alur analisis mencakup data understanding, exploratory data analysis, data cleaning, label encoding, feature engineering, balancing menggunakan SMOTE, seleksi fitur menggunakan Mutual Information, Chi-Square, ANOVA F-test, dan embedded Decision Tree importance, serta pemodelan menggunakan Gaussian Naive Bayes dan Decision Tree Classifier. Hasil pengujian menunjukkan bahwa Decision Tree memperoleh performa terbaik dengan accuracy 0,9225, weighted F1-score 0,9232, dan weighted ROC-AUC OVR 0,9833, sedangkan Naive Bayes memperoleh accuracy 0,8495, weighted F1-score 0,8487, dan weighted ROC-AUC OVR 0,9640. Fitur yang paling kuat berkaitan dengan kelas hasil panen adalah Fertilizer_Used_kg, Input_Intensity, Fertilizer_per_Density, Rainfall_mm, dan Rainfall_per_Temperature. Temuan ini menunjukkan bahwa klasifikasi tingkat produktivitas dapat menjadi pendekatan pendukung keputusan yang lebih operasional ketika tujuan pengguna bukan memprediksi angka yield secara presisi, melainkan mengelompokkan risiko hasil panen ke dalam kategori tindakan.

BUSINESS OBJECTIVE

Sektor pertanian menghadapi ketidakpastian tinggi karena hasil panen dipengaruhi oleh interaksi antara kondisi tanah, cuaca, input budidaya, serta keputusan manajemen lahan. Dalam konteks pertanian presisi, machine learning banyak digunakan untuk membantu estimasi produktivitas, perencanaan input, dan pengambilan keputusan berbasis data. Kajian terdahulu menunjukkan bahwa pendekatan machine learning telah diterapkan secara luas untuk prediksi hasil panen dan estimasi kondisi nitrogen tanaman [1], sedangkan systematic literature review lain menunjukkan bahwa variabel cuaca, tanah, dan input budidaya menjadi kelompok fitur yang sering digunakan dalam studi crop yield prediction [2].

Tujuan bisnis pada mini project ini adalah membangun model klasifikasi tingkat hasil panen tanaman ke dalam kelas Low, Medium, dan High berdasarkan atribut lingkungan, karakteristik tanah, praktik budidaya, dan riwayat tanaman. Pendekatan klasifikasi dipilih karena lebih mudah diterjemahkan menjadi keputusan operasional. Sebagai contoh, kelas Low dapat menjadi sinyal perlunya evaluasi input budidaya, kelas Medium dapat menjadi indikator kondisi normal, sedangkan kelas High dapat digunakan sebagai acuan pola perlakuan yang berpotensi produktif.

Gap penelitian atau gap pekerjaan pada proyek ini terletak pada pergeseran orientasi dari prediksi nilai yield kontinu menuju klasifikasi kelas produktivitas yang lebih dekat dengan kebutuhan keputusan lapangan. Banyak studi crop yield prediction berfokus pada model regresi dan perbandingan akurasi numerik [1,2]. Laporan awal proyek ini juga menggunakan pendekatan regresi dengan Linear Regression, Decision Tree Regressor, dan Random Forest Regressor. Namun, pendekatan tersebut belum menguji bagaimana yield numerik dapat dikonversi menjadi kelas keputusan Low, Medium, dan High, belum menerapkan balancing dataset untuk kelas target, serta belum membandingkan model probabilistik sederhana seperti Gaussian Naive Bayes dengan model pohon keputusan yang lebih interpretatif. Dengan demikian, kontribusi mini project ini adalah menyusun pipeline klasifikasi yang lebih sesuai untuk pengambilan keputusan berbasis kategori produktivitas.

ORIGINAL DATA

Dataset yang digunakan adalah Smart Crop Yield Prediction Dataset yang bersumber dari Kaggle [3]. Data terdiri atas 10.000 observasi dan 13 kolom. Terdapat 12 atribut prediktor awal dan satu atribut target numerik, yaitu

Yield_ton_per_ha. Prediktor mencakup lima variabel kategorikal, yaitu Crop, Region, Soil_Type, Irrigation, dan Previous_Crop, serta tujuh variabel numerik, yaitu Soil_pH, Rainfall_mm, Temperature_C, Humidity_pct, Fertilizer_Used_kg, Pesticides_Used_kg, dan Planting_Density.

TABLE 1. Deskripsi atribut dataset

No	Nama Kolom	Tipe Data	Deskripsi
1	Crop	Kategorikal	Jenis tanaman yang ditanam: Maize, Barley, Rice, dan Wheat.
2	Region	Kategorikal	Wilayah geografis penanaman, yaitu Region_A sampai Region_D.
3	Soil_Type	Kategorikal	Jenis tanah, yaitu Sandy, Loam, dan Clay.
4	Soil_pH	Numerik	Tingkat keasaman tanah.
5	Rainfall_mm	Numerik	Curah hujan selama masa tanam dalam milimeter.
6	Temperature_C	Numerik	Rata-rata suhu udara dalam derajat Celsius.
7	Humidity_pct	Numerik	Tingkat kelembapan udara dalam persen.
8	Fertilizer_Used_kg	Numerik	Jumlah pupuk yang digunakan dalam kilogram.
9	Irrigation	Kategorikal	Metode pengairan yang digunakan.
10	Pesticides_Used_kg	Numerik	Jumlah pestisida yang digunakan dalam kilogram.
11	Planting_Density	Numerik	Kepadatan tanaman pada lahan.
12	Previous_Crop	Kategorikal	Jenis tanaman pada periode sebelumnya.
13	Yield_ton_per_ha	Numerik / target awal	Hasil panen dalam ton per hektar.

DATA UNDERSTANDING

Pemeriksaan awal menunjukkan bahwa dataset memiliki dua kolom dengan missing value, yaitu Irrigation sebanyak 2.538 baris atau 25,38% dan Previous_Crop sebanyak 2.031 baris atau 20,31%. Kolom lain tidak memiliki missing value. Target numerik Yield_ton_per_ha memiliki nilai minimum 28,45 ton/ha, maksimum 207,21 ton/ha, rata-rata sekitar 117,89 ton/ha, dan median sekitar 117,71 ton/ha. Distribusi target relatif simetris, sehingga pembentukan kelas berbasis kuantil dapat menghasilkan distribusi instance yang seimbang.

TABLE 2. Ringkasan kualitas data awal

Aspek	Keterangan
Jumlah observasi	10.000 baris
Jumlah kolom	13 kolom
Prediktor awal	12 fitur
Target awal	Yield_ton_per_ha
Missing value Irrigation	2.538 baris
Missing value Previous_Crop	2.031 baris
Duplikasi data	0 baris
Rentang yield	28,45 sampai 207,21 ton/ha

EXPLORATORY DATA ANALYSIS

EDA dilakukan untuk memahami distribusi target, keseimbangan kategori, korelasi antarfitur numerik, dan potensi masalah kualitas data sebelum pemodelan. Histogram pada Fig. 1 memperlihatkan bahwa yield menyebar cukup lebar, tetapi tidak menunjukkan kemencengan tajam. Kondisi ini memungkinkan target dibagi menggunakan kuantil agar kelas Low, Medium, dan High memiliki jumlah instance yang hampir sama.

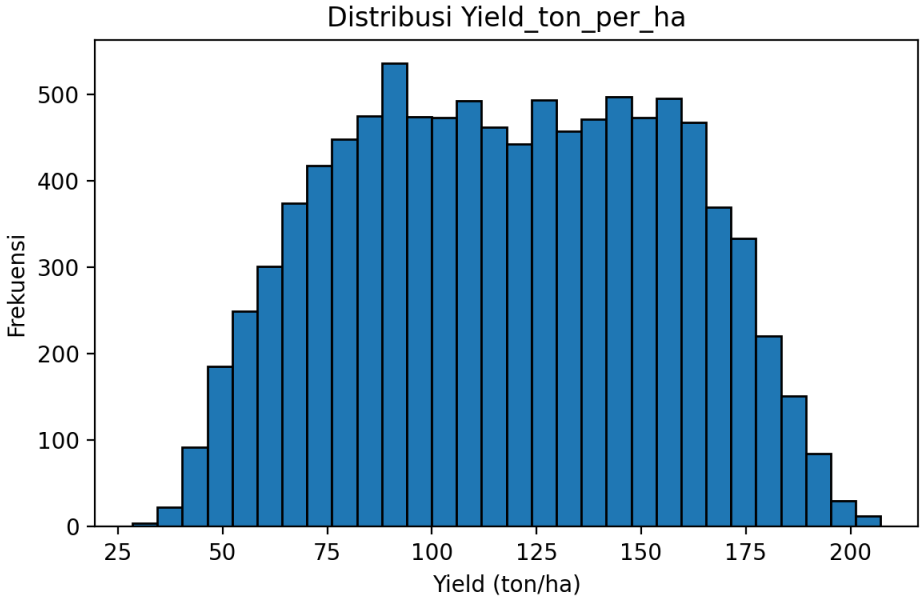


FIGURE 1. Histogram distribusi Yield_ton_per_ha

Setelah target numerik dikonversi menjadi kelas, distribusi instance menjadi relatif seimbang. Kelas Low berisi 3.333 instance, Medium berisi 3.333 instance, dan High berisi 3.334 instance. Distribusi ini penting karena model klasifikasi tidak diarahkan untuk mempelajari kelas mayoritas saja.

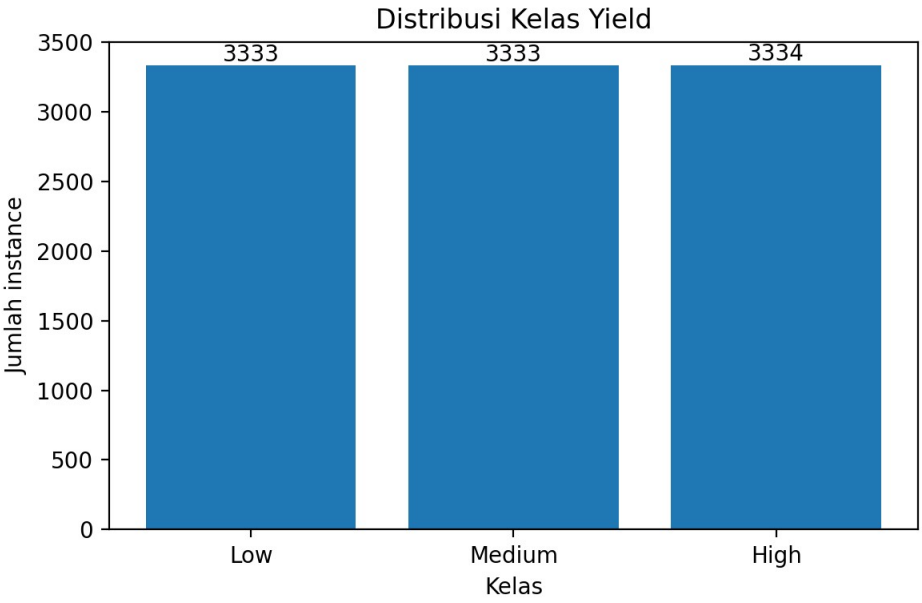


FIGURE 2. Distribusi kelas hasil panen setelah konversi target

Heatmap korelasi numerik pada Fig. 3 menunjukkan bahwa Fertilizer_Used_kg mempunyai hubungan paling kuat dengan Yield_ton_per_ha, sedangkan Rainfall_mm menjadi prediktor sekunder. Temuan ini konsisten dengan hasil seleksi fitur dan feature importance pada tahap modelling.

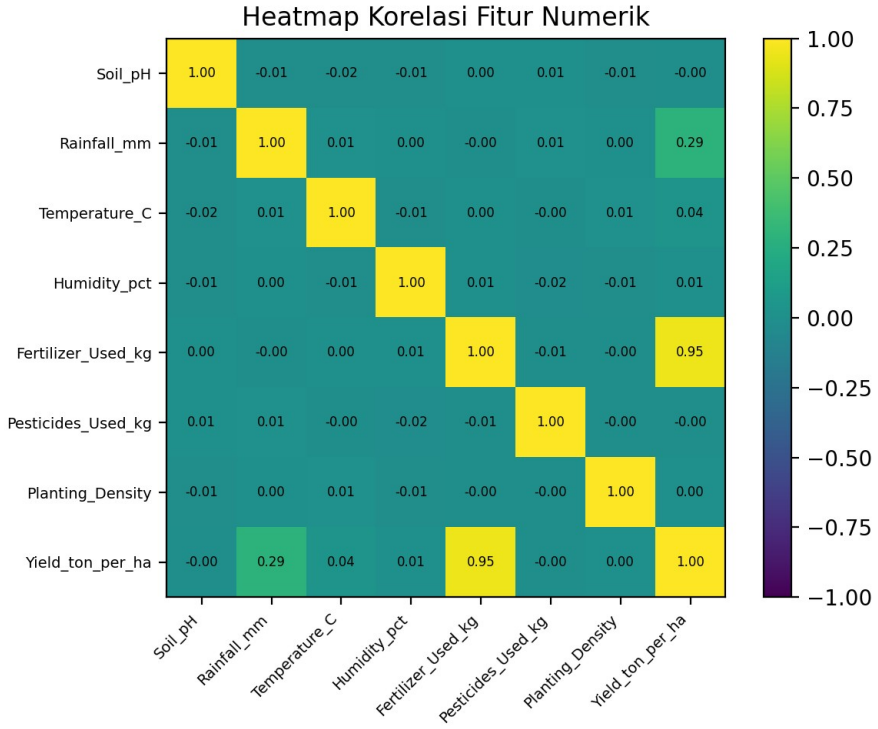


FIGURE 3. Heatmap korelasi fitur numerik

TARGET DATA

Target awal pada dataset adalah Yield_ton_per_ha yang berbentuk numerik kontinu. Karena notebook baru menggunakan algoritma klasifikasi, target ini dikonversi menjadi tiga kelas produktivitas menggunakan pembagian kuantil. Batas kuantil yang dihasilkan adalah 28,45 sampai 96,72 ton/ha untuk kelas Low, 96,72 sampai 139,07 ton/ha untuk kelas Medium, dan 139,07 sampai 207,21 ton/ha untuk kelas High. Konversi ini tidak dimaksudkan untuk menggantikan pendekatan regresi sepenuhnya, tetapi untuk menyediakan keluaran yang lebih mudah digunakan dalam keputusan kategoris.

TABLE 3. Definisi kelas target

Kelas	Rentang yield ton/ha	Makna operasional
Low	28,45 <= yield <= 96,72	Produktivitas rendah; perlu evaluasi input atau kondisi lahan.
Medium	96,72 < yield <= 139,07	Produktivitas sedang; kondisi relatif normal.
High	139,07 < yield <= 207,21	Produktivitas tinggi; pola input dapat dijadikan acuan.

DATA PRE-PROCESSING AND TRANSFORMATION

Data Cleaning

Tahap cleaning dilakukan dengan mempertahankan seluruh observasi. Missing value pada Irrigation dan Previous_Crop tidak dihapus karena proporsinya cukup besar. Kedua kolom tersebut diisi dengan kategori Unknown agar sinyal ketiadaan informasi tetap dapat dipelajari oleh model. Variabel numerik diisi dengan median jika ditemukan missing value, walaupun pada dataset ini seluruh fitur numerik lengkap.

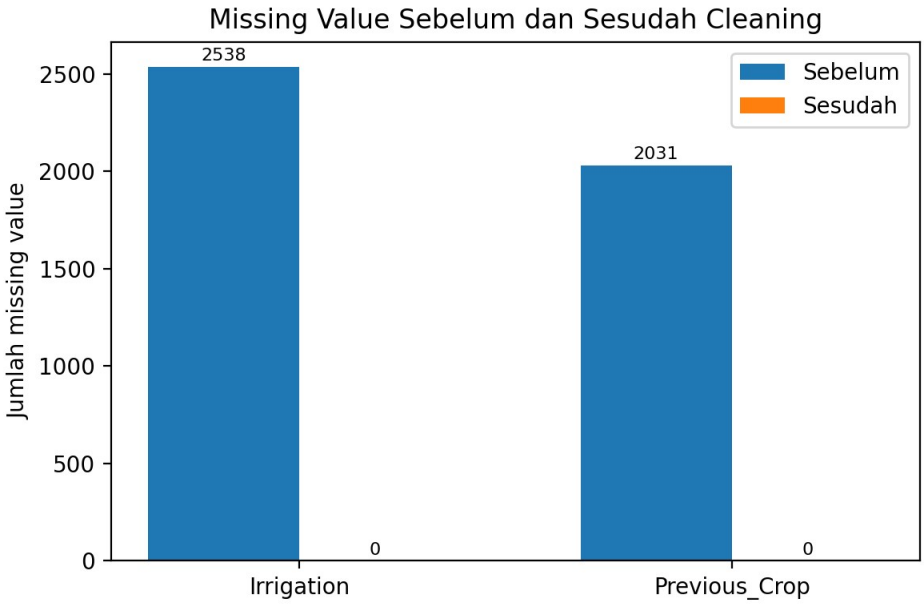


FIGURE 4. Perbandingan missing value sebelum dan sesudah cleaning

Label Encoding

Label encoding digunakan untuk mengubah fitur kategorikal menjadi angka. Teknik ini diterapkan pada Crop, Region, Soil_Type, Irrigation, dan Previous_Crop. Target kelas juga dipetakan secara eksplisit menjadi Low = 0, Medium = 1, dan High = 2 agar urutan kelas sesuai dengan tingkat produktivitas. Meskipun label encoding dapat memberi kesan urutan pada kategori nominal, pendekatan ini tetap digunakan karena struktur notebook meminta adanya tahap label encoding dan model Decision Tree dapat menggunakan nilai kategori sebagai dasar pemisahan. Untuk penelitian lanjutan, one-hot encoding dapat diuji sebagai pembanding.

Feature Engineering

Feature engineering dilakukan dengan menambahkan empat fitur turunan berbasis domain, yaitu Rainfall_per_Temperature, Fertilizer_per_Density, Humidity_Temperature_Index, dan Input_Intensity. Fitur turunan ini dibentuk untuk menangkap interaksi sederhana antara curah hujan, suhu, kepadatan tanam, pupuk, pestisida, dan kelembapan. Secara praktis, Input_Intensity membantu merangkum total input budidaya yang diberikan ke lahan, sedangkan Fertilizer_per_Density membantu memahami intensitas pupuk relatif terhadap kepadatan tanam.

TABLE 4. Ringkasan preprocessing dan transformasi

Tahap	Keputusan teknis
Missing value kategorikal	Irrigation dan Previous_Crop diisi Unknown
Label encoding	Crop, Region, Soil_Type, Irrigation, Previous_Crop, dan target kelas
Feature engineering	Empat fitur turunan interaksi dan rasio
Train-test split	80% data latih dan 20% data uji dengan stratifikasi target
Balancing dataset	SMOTE diterapkan pada data latih
Jumlah fitur setelah engineering	16 fitur sebelum seleksi
Jumlah fitur final	10 fitur setelah seleksi fitur

DISTRIBUSI INSTANCE, TRAIN-TEST SPLIT, AND BALANCING

Distribusi kelas setelah target dikonversi relatif seimbang. Data kemudian dibagi menjadi 80% data latih dan 20% data uji menggunakan stratified train-test split. Pada data latih, SMOTE diterapkan untuk memastikan setiap kelas

memiliki jumlah instance yang sama. Rumus dasar SMOTE membentuk data sintetis dengan menarik titik baru di antara satu instance minoritas dan tetangga terdekatnya [4]:

$$x_{\text{new}} = x_i + \lambda(x_{\text{nn}} - x_i), \quad 0 \le \lambda \le 1 \tag{1}$$

TABLE 5. Distribusi instance sebelum dan sesudah balancing

Kelas	Data awal	Data latih	Data latih setelah SMOTE
Low	3.333	2.666	2.667
Medium	3.333	2.667	2.667
High	3.334	2.667	2.667

FEATURE SELECTION

Seleksi fitur pada notebook baru menggunakan empat pendekatan. Mutual Information digunakan sebagai algoritma utama untuk memilih fitur final karena dapat menangkap hubungan nonlinier antara fitur dan kelas target. Chi-Square digunakan sebagai pembanding untuk melihat asosiasi antara fitur non-negatif dan target kelas. ANOVA F-test digunakan untuk mengukur perbedaan rata-rata fitur antar kelas. Embedded Decision Tree importance digunakan untuk melihat kontribusi fitur berdasarkan penurunan impurity pada model pohon keputusan. Dengan demikian, seleksi fitur tidak hanya bergantung pada satu ukuran statistik.

Mutual Information mengukur seberapa besar informasi suatu fitur X terhadap kelas Y melalui persamaan berikut:

$$I(X;Y) = \sum_{x \in X} \sum_{y \in Y} p(x,y) \log \left(\frac{p(x,y)}{p(x)p(y)} \right) \tag{2}$$

Chi-Square mengukur selisih antara frekuensi observasi dan frekuensi harapan melalui persamaan berikut:

$$\chi^2 = \sum_i \frac{(O_i - E_i)^2}{E_i} \tag{3}$$

ANOVA F-test membandingkan variasi antar kelas dengan variasi dalam kelas melalui rasio berikut:

$$F = \frac{MS_{\text{between}}}{MS_{\text{within}}} \tag{4}$$

Feature importance pada Decision Tree dihitung dari total penurunan impurity yang disumbangkan oleh suatu fitur melalui persamaan berikut:

$$FI_j = \sum_{t\,:\,v(t)=j} \frac{N_t}{N} \left[I_t - \frac{N_L}{N_t} I_L - \frac{N_R}{N_t} I_R \right] \tag{5}$$

TABLE 6. Algoritma seleksi fitur yang digunakan

Metode	Cara kerja ringkas	Peran dalam proyek
Mutual Information	Menangkap asosiasi nonlinier fitur-target	Algoritma utama untuk memilih 10 fitur final
Chi-Square	Mengukur asosiasi fitur non-negatif dengan kelas	Pembanding statistik setelah fitur diskalakan ke rentang non-negatif
ANOVA F-test	Menguji perbedaan rata-rata fitur antar kelas	Pembanding untuk fitur numerik

Decision Tree Importance	Mengukur penurunan impurity akibat suatu fitur	Interpretasi embedded berbasis model pohon

TABLE 7. Fitur final hasil seleksi Mutual Information

No	Fitur terpilih
1	Region
2	Soil_Type
3	Soil_pH
4	Rainfall_mm
5	Humidity_pct
6	Fertilizer_Used_kg
7	Pesticides_Used_kg
8	Rainfall_per_Temperature
9	Fertilizer_per_Density
10	Input_Intensity

DATA MINING ALGORITHMS

Gaussian Naive Bayes

Gaussian Naive Bayes adalah model probabilistik yang menggunakan Teorema Bayes dan mengasumsikan bahwa setiap fitur bersifat independen secara kondisional terhadap kelas [5]. Untuk sebuah instance x = (x_1, x_2, ..., x_n), model memilih kelas dengan probabilitas posterior terbesar:

$$P(C_k \mid x) = \frac{P(C_k)\prod_i P(x_i \mid C_k)}{P(x)} \tag{6}$$

Karena fitur yang digunakan bersifat numerik, notebook menggunakan Gaussian Naive Bayes. Likelihood setiap fitur diasumsikan mengikuti distribusi normal:

$$P(x_i \mid C_k) = \frac{1}{\sqrt{2\pi\sigma_k^2}} \exp\left[-\frac{(x_i - \mu_k)^2}{2\sigma_k^2}\right] \tag{7}$$

Cara kerjanya adalah menghitung prior setiap kelas, menghitung parameter rata-rata dan varians fitur pada masing-masing kelas, lalu memilih kelas dengan nilai posterior terbesar. Model ini cepat, mudah dijelaskan, dan menjadi baseline probabilistik yang baik, tetapi performanya dapat turun jika asumsi independensi fitur terlalu kuat.

Decision Tree Classifier

Decision Tree Classifier membangun struktur keputusan berbentuk pohon. Setiap node memilih fitur dan ambang pemisahan yang menghasilkan penurunan impurity terbesar. Dalam notebook ini, criterion yang digunakan adalah Gini impurity. Konsep decision tree klasik telah lama digunakan untuk induksi aturan klasifikasi berbasis data [6]. Rumus Gini impurity adalah:

$$Gini(D) = 1 - \sum_k p_k^2 \tag{8}$$

Untuk sebuah split menjadi subset kiri dan kanan, impurity gabungan dihitung sebagai:

$$Gini_{\text{split}} = \frac{n_L}{n} Gini(D_L) + \frac{n_R}{n} Gini(D_R) \tag{9}$$

Model memilih split yang memaksimalkan penurunan Gini:

$$\Delta Gini = Gini(D) - Gini_{\text{split}} \quad (10)$$

Cara kerja Decision Tree dimulai dari seluruh data latih, memilih split terbaik, membagi data ke cabang kiri dan kanan, lalu mengulangi proses sampai mencapai batas kedalaman, jumlah minimum sampel, atau kondisi node yang sudah cukup homogen. Pada notebook ini Decision Tree dibatasi dengan max_depth = 5, min_samples_split = 10, dan min_samples_leaf = 5 agar model tidak terlalu kompleks.

MODEL EVALUATION

Evaluasi dilakukan menggunakan data uji sebanyak 2.000 observasi. Metrik yang digunakan meliputi accuracy, weighted precision, weighted recall, weighted F1-score, weighted ROC-AUC OVR, confusion matrix, classification report, dan ROC curve. Karena kelas target seimbang, accuracy tetap informatif, sedangkan weighted F1-score digunakan untuk menjaga interpretasi yang mempertimbangkan precision dan recall setiap kelas.

TABLE 8. Hasil evaluasi model pada data uji

Model	Accuracy	Precision	Recall	F1-score	ROC-AUC OVR
Decision Tree	0.9225	0.9251	0.9225	0.9232	0.9833
Naive Bayes	0.8495	0.8484	0.8495	0.8487	0.9640

Berdasarkan Tabel 8, Decision Tree menghasilkan performa terbaik dengan accuracy 0,9225 dan weighted F1-score 0,9232. Naive Bayes berada di posisi kedua dengan accuracy 0,8495 dan weighted F1-score 0,8487. Perbedaan ini menunjukkan bahwa pola pembeda kelas yield tidak sepenuhnya memenuhi asumsi independensi fitur yang digunakan Naive Bayes. Decision Tree lebih mampu menangkap ambang keputusan pada fitur seperti Fertilizer_Used_kg, Input_Intensity, dan Rainfall_mm.

TABLE 9. Hasil cross validation lima fold pada data latih seimbang

Model	Accuracy mean ± std	Precision mean	Recall mean	F1 mean ± std
Decision Tree	0.9184 ± 0.0069	0.9197	0.9184	0.9187 ± 0.0066
Naive Bayes	0.8421 ± 0.0076	0.8416	0.8421	0.8417 ± 0.0080

Cross validation memperkuat hasil data uji. Decision Tree memperoleh rata-rata F1-score 0,9187, sedangkan Naive Bayes memperoleh rata-rata F1-score 0,8417. Selisih antara evaluasi data uji dan cross validation relatif kecil, sehingga model tidak menunjukkan indikasi ketidakstabilan yang besar.

Confusion Matrix and Classification Report

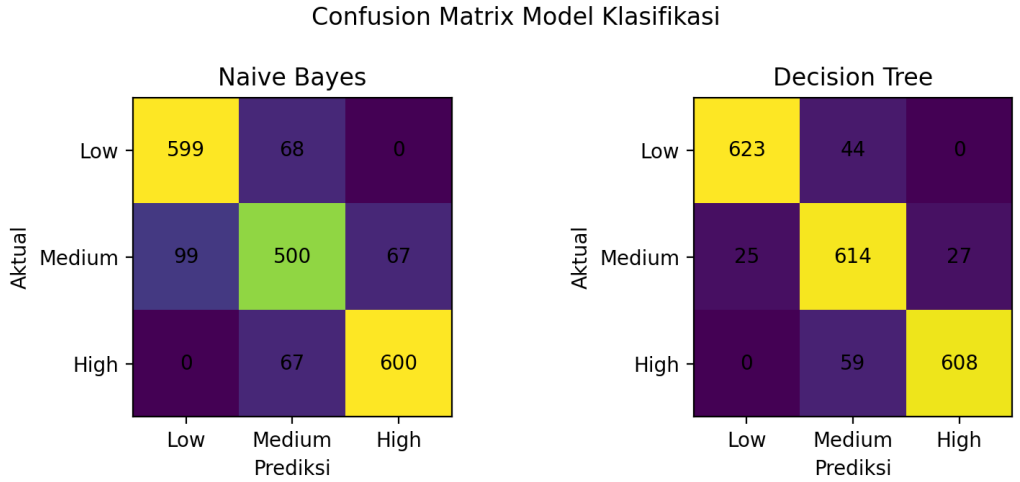


FIGURE 5. Confusion matrix Naive Bayes dan Decision Tree

TABLE 10. Ringkasan classification report pada data uji

Model	Kelas	Precision	Recall	F1-score	Support

Naive Bayes	Low	0,8582	0,8981	0,8777	667
Naive Bayes	Medium	0,7874	0,7508	0,7686	666
Naive Bayes	High	0,8996	0,8996	0,8996	667
Decision Tree	Low	0,9614	0,9340	0,9475	667
Decision Tree	Medium	0,8563	0,9219	0,8879	666
Decision Tree	High	0,9575	0,9115	0,9339	667

Kesalahan terbesar pada kedua model terjadi pada kelas Medium. Hal ini wajar karena kelas Medium berada di antara Low dan High sehingga lebih berpotensi tumpang tindih dengan batas kelas sekitarnya. Decision Tree tetap lebih stabil karena mampu menekan kesalahan antara Low dan High, sedangkan Naive Bayes masih lebih sering salah membedakan Low-Medium dan Medium-High.

ROC Curve

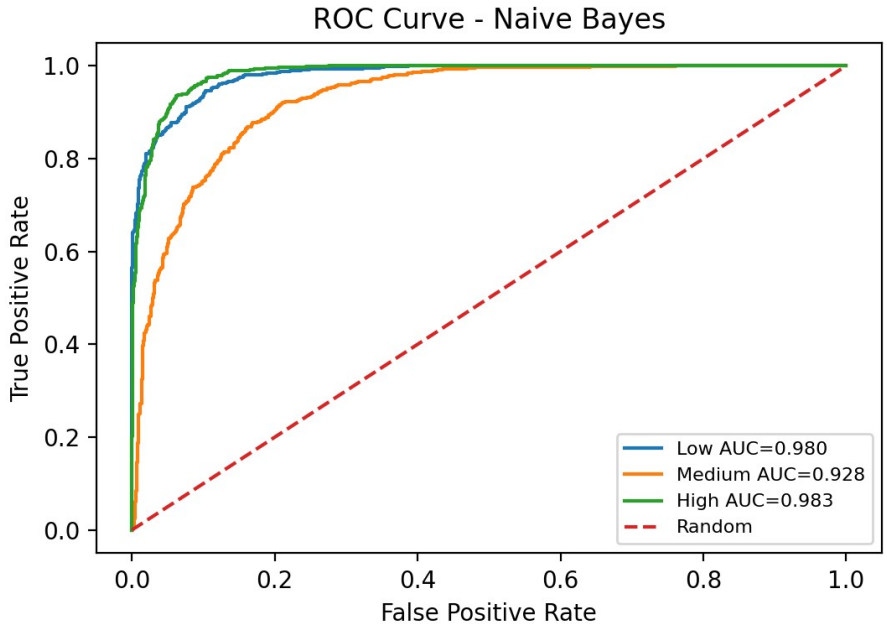


FIGURE 6. ROC curve Naive Bayes

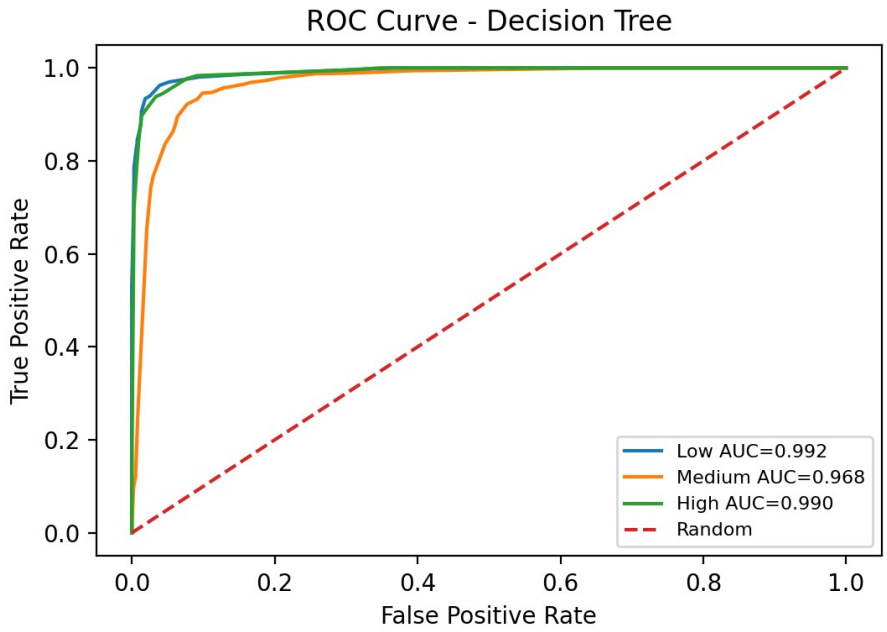


FIGURE 7. ROC curve Decision Tree

ROC curve menunjukkan bahwa kedua model memiliki kemampuan diskriminasi yang baik. Decision Tree memperoleh weighted ROC-AUC OVR 0,9833, sedangkan Naive Bayes memperoleh 0,9640. Nilai ini mengindikasikan bahwa probabilitas prediksi model, terutama Decision Tree, cukup kuat untuk membedakan kelas Low, Medium, dan High.

FEATURE IMPORTANCE AND DECISION TREE VISUALIZATION

Feature importance dari Decision Tree menunjukkan bahwa Fertilizer_Used_kg dan Rainfall_mm menjadi fitur paling dominan. Hasil ini sejalan dengan EDA dan seleksi fitur yang menempatkan input pupuk, intensitas input, dan curah hujan sebagai sinyal utama dalam pembentukan kelas yield. Namun, interpretasi feature importance harus dibaca sebagai kontribusi model, bukan bukti kausal bahwa penambahan pupuk selalu meningkatkan hasil panen.

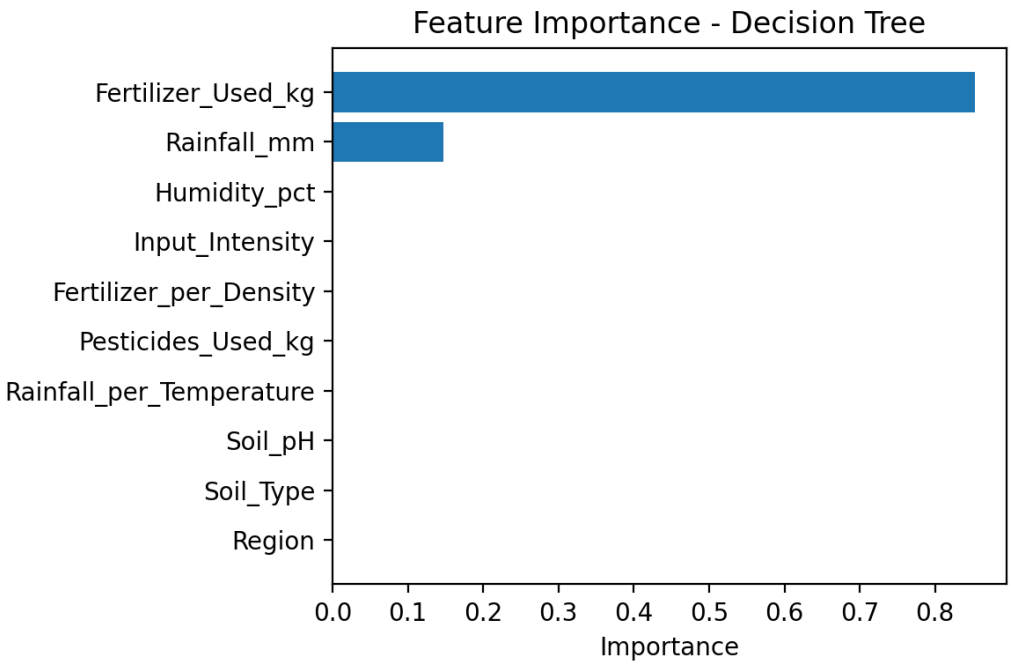


FIGURE 8. Feature importance berdasarkan Decision Tree

Visualisasi pohon keputusan pada Fig. 9 memperlihatkan bahwa model membentuk aturan klasifikasi secara bertahap. Karena pohon lengkap dapat cukup besar, visualisasi dibatasi hingga kedalaman tertentu agar tetap terbaca. Visualisasi ini berguna untuk menjelaskan arah keputusan model, sedangkan evaluasi akhir tetap mengacu pada metrik data uji dan cross validation.

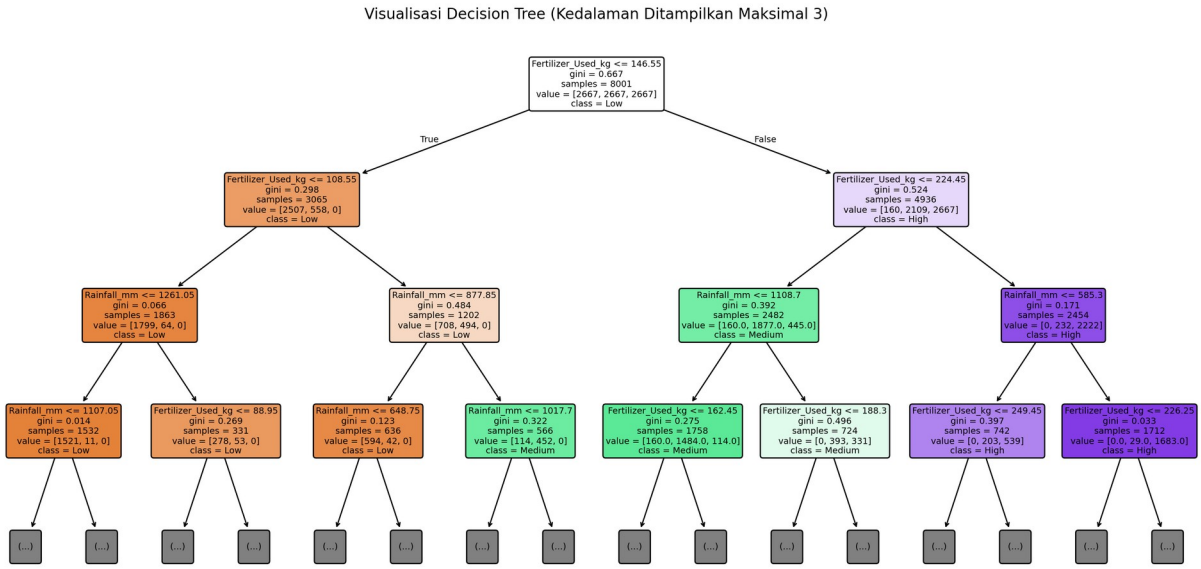


FIGURE 9. Visualisasi Decision Tree dengan kedalaman tampilan maksimal tiga level

PREDICTION OF NEW DATA AND SAVE MODEL

Notebook menyediakan contoh prediksi data baru dengan mengambil satu instance dari data uji, menerapkan seleksi fitur yang sama, lalu menghasilkan prediksi kelas menggunakan model Decision Tree. Paket model yang disimpan

mencakup Naive Bayes, Decision Tree, selector, daftar fitur terpilih, label encoders, class mapping, yield bins, dan catatan metodologis. Penyimpanan model dilakukan menggunakan joblib agar pipeline dapat digunakan kembali pada sesi Colab berikutnya.

MODEL COMPARISON AND SUMMARY

Perbandingan model menunjukkan bahwa Decision Tree lebih unggul daripada Naive Bayes pada seluruh metrik utama. Keunggulan ini dapat dijelaskan oleh kemampuan Decision Tree untuk menangkap hubungan ambang dan interaksi antarfitur. Naive Bayes tetap berguna sebagai baseline karena sederhana, cepat, dan memberikan pembanding probabilistik. Fitur terpilih menunjukkan bahwa aspek input budidaya, terutama pupuk dan kombinasi input, lebih dominan dibandingkan identitas tanaman saja.

TABLE 11. Ringkasan hasil utama

Aspek	Hasil
Model terbaik	Decision Tree Classifier
Accuracy model terbaik	0,9225
Weighted F1-score model terbaik	0,9232
Weighted ROC-AUC OVR model terbaik	0,9833
Baseline pembanding	Gaussian Naive Bayes
Metode balancing	SMOTE pada data latih
Metode seleksi fitur utama	Mutual Information
Fitur paling penting	Fertilizer_Used_kg dan Rainfall_mm
Gap yang dijawab	Klasifikasi kelas produktivitas Low-Medium-High, bukan hanya regresi yield numerik

CONCLUSION

Berdasarkan hasil eksperimen, notebook baru berhasil mengubah orientasi proyek dari prediksi regresi yield numerik menjadi klasifikasi tingkat produktivitas hasil panen. Target Yield_ton_per_ha dikonversi menjadi kelas Low, Medium, dan High menggunakan kuantil sehingga distribusi kelas relatif seimbang. Proses data mining mencakup data cleaning, label encoding, feature engineering, train-test split, balancing menggunakan SMOTE, seleksi fitur, pemodelan, cross validation, confusion matrix, classification report, ROC curve, feature importance, visualisasi Decision Tree, prediksi data baru, dan save model.

Decision Tree Classifier menjadi model terbaik dengan accuracy 0,9225, weighted F1-score 0,9232, dan weighted ROC-AUC OVR 0,9833. Naive Bayes tetap bermanfaat sebagai baseline dengan accuracy 0,8495 dan weighted F1-score 0,8487, tetapi performanya lebih rendah karena asumsi independensi fitur kurang sesuai dengan struktur data. Seleksi fitur menunjukkan bahwa Fertilizer_Used_kg, Input_Intensity, Fertilizer_per_Density, Rainfall_mm, dan Rainfall_per_Temperature memiliki kontribusi penting dalam pembentukan kelas produktivitas.

Keterbatasan utama proyek ini adalah target klasifikasi dibentuk dari kuantil dataset, bukan dari standar agronomis eksternal. Oleh karena itu, kelas Low, Medium, dan High bersifat relatif terhadap distribusi data, bukan kategori universal. Penelitian lanjutan dapat membandingkan label encoding dengan one-hot encoding, menggunakan threshold agronomis yang lebih substantif, serta menguji model lain seperti Random Forest Classifier, Gradient Boosting, Support Vector Machine, atau model regresi jika tujuan akhirnya adalah memprediksi nilai yield ton/ha secara langsung.

REFERENCES

1. A. Chlingaryan, S. Sukkarieh, and B. Whelan, “Machine learning approaches for crop yield prediction and nitrogen status estimation in precision agriculture: A review,” Computers and Electronics in Agriculture 151, 61–69 (2018).

2. T. van Klompenburg, A. Kassahun, and C. Catal, “Crop yield prediction using machine learning: A systematic literature review,” Computers and Electronics in Agriculture 177, 105709 (2020).

3. M. I. Miadul, “Smart Crop yield predication dataset,” Kaggle Dataset (2025).

4. N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic Minority Over-sampling Technique,” Journal of Artificial Intelligence Research 16, 321–357 (2002).

5. I. Rish, “An empirical study of the naive Bayes classifier,” in IJCAI 2001 Workshop on Empirical Methods in Artificial Intelligence (2001), pp. 41–46.

6. J. R. Quinlan, “Induction of decision trees,” Machine Learning 1, 81–106 (1986).

7. L. Breiman, “Random forests,” Machine Learning 45, 5–32 (2001).

8. S. M. Shawon, F. B. Ema, A. K. Mahi, F. L. Niha, and H. T. Zubair, “Crop yield prediction using machine learning: An extensive and systematic literature review,” Smart Agricultural Technology 10, 100718 (2025).